



Aprendizado por Reforço na Seleção de Clientes para Identificação Distribuída de Plantas Daninhas

Elisa Veloso



Agenda

- Introdução
- Objetivos
- Conjunto de Dados
- Modelagem
- Resultados
- Conclusão

Introdução

O Brasil é o maior produtor mundial de cana-de-açúcar, responsável por cerca de 37% da produção global, e o maior exportador de açúcar, respondendo por aproximadamente 50% das exportações mundiais.

O país também lidera a produção e exportação de bioetanol, um combustível sustentável derivado da cana

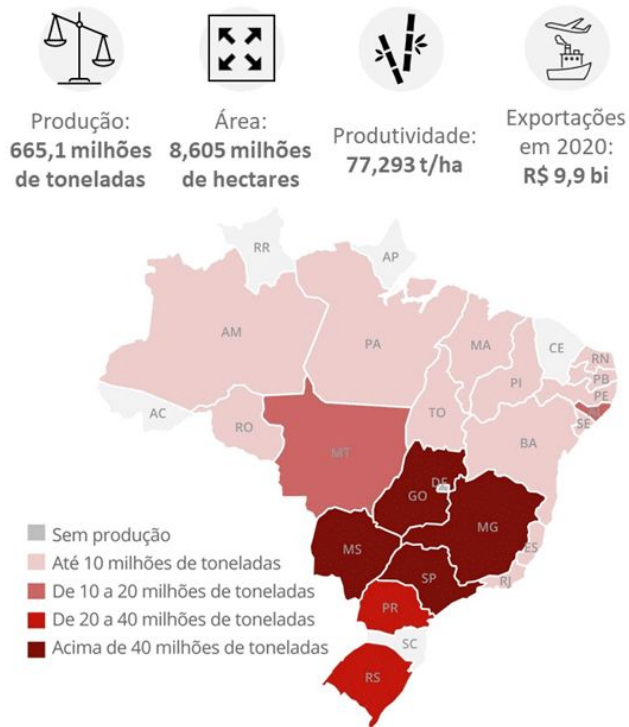


Figura 1: Mapa da produção de cana-de-açúcar no Brasil, construído a partir de dados fornecidos pela Conab e pela Secex. Fonte: Adaptado de G1 (2021).

AGRO é tech.

AGRO é pop.

AGRO é tudo.

Introdução


A interferência das plantas daninhas na cultura da cana-de-açúcar pode levar a perdas de produtividade de até 85% se não forem controladas.



Figura 2.
Matocompetição na
cultura da
cana-de-açúcar por
Ipomoea sp. Foto:
Rodrigo Alff, disponível
em elevagro.com

Introdução

Grandes produtores de cana de açúcar investem em tecnologia para melhorar seu rendimento de produção, mas esbarram na preocupação da proteção de seus dados.



Fonte: FG/A (2025)

Figura 3. Ranking de moagem de cana-de-açúcar na Safra 2024/25, em milhões de toneladas. Fonte: FG/A (2025).

Introdução

Enquanto o Aprendizado Federado pode apoiar na segurança dada ao produtor ao contratar serviços de agricultura de precisão, as combinações de seus clientes são diversas

Será utilizado um Agente de RL para otimizar a seleção de clientes desse treinamento federado




Figura 4. Esquema da abordagem do Aprendizado Federado



Objetivos

Propor a integração de um agente de Aprendizado por Reforço no processo de Aprendizagem Federada na identificação de plantas daninhas nas lavouras de cana-de-açúcar, preservando os dados dos produtores

Conjunto de Dados

- Foram utilizados as imagens do dataset “Sugarcane and Weed”, disponível no [Kaggle](#)
- Pré-processamento dos dados incluiu:
 - Normalização e redimensionamento das imagens;
 - Remoção de amostras corrompidas ou redundantes;
 - Aplicação de técnicas de aumento de dados;
- Cada classe contou com 524 imagens




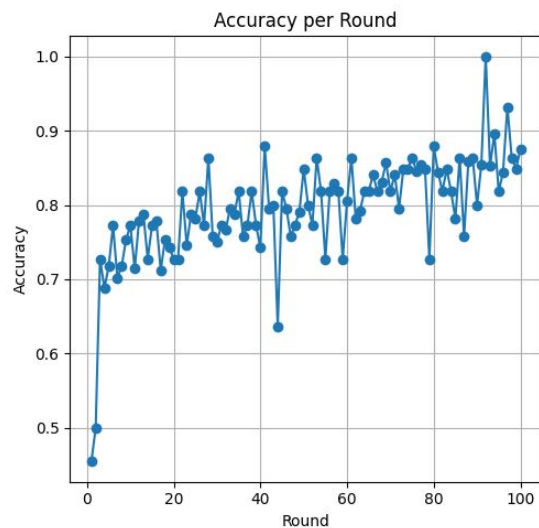
Figuras 5 e 6.
Representações
das classes no
dataset






Modelagem

- Estados:
 - Dupla contendo o índice da rodada atual e a acurácia global da rodada anterior
- Ação:
 - Seleção discreta do número de clientes participantes
- Recompensa:
 - Formulada como a acurácia obtida na rodada atual penalizada linearmente pelo número de clientes utilizados $r = \text{Acc} - 0.01 * K$, incentivando a eficiência de recursos

Resultados



Resultados



| Rodadas | Acurácia | Recompensa | Custo |
|--------------------|----------|-------------|---------------------------|
| 5 e 6 (5 clientes) | 73-76% | 0.68 - 0.71 | Alto (5 clientes = -0.05) |
| 8 (1 cliente) | 81% | 0.80 | Baixo (1 cliente = -0.01) |



Discussões

A integração AF + RL tem muito potencial para a seleção ideal de clientes utilizados na agregação

As possibilidades dessa integração são diversas: agentes nos clientes, agentes no servidor agregador, ambos

As possibilidades de otimização também são diversas: além da alteração dos parâmetros de treinamento no RL, pode-se otimizar outros parâmetros do AF: nº de clientes, tipo de agregação, distribuição das classes



Referências

AMARAL, F. C. R.; NEPOMUCENO, M. P. Períodos de interferência de plantas daninhas na cana-de-açúcar cultivada em sistema de mudas pré-brotadas. Planta Daninha, Viçosa-MG, v. 37, 2019. Disponível em: <https://www.scielo.br/j/pd/a/yXrXRCrkGX9j9Rw49DPmpQF/?lang=en>

L. Wang X. Zhao and J. Liu. Fedppo: Reinforcement learning-based client selection for federated learning with heterogeneous data. preprint, 2024.

Z. Liu B. Ding Y. Sun W. Zhang, Y. Jiang and Y. Wang. Adaptive client selection in resource-constrained federated learning systems: A deep reinforcement learning approach. Computer Communications, 188:56 – 66, 2022.

Dhirendra Kumar Domah. Sugarcane and weed dataset. Kaggle Dataset, 2025.

Pengfei Guo, Dong Yang, Ali Hatamizadeh, An Xu, Ziyue Xu, Wenqi Li, Can Zhao, Daguang Xu, Stephanie armon, Evrim Turkbey, Baris Turkbey, Bradford Wood, Francesca Patella, Elvira Stellato, Gianpaolo Carrafiello, Vishal M. Patel, and Holger R.Roth. Auto-fedrl: Federated hyperparameter optimization for multi-institutional medical image segmentation, 2022